

Prediksi Kebutuhan Obat Menggunakan Artificial Neural Network

pada Sistem Informasi Manajemen Stok Obat

Abstrak

Prediksi jumlah kebutuhan obat pada fasilitas kesehatan sangat dibutuhkan untuk menjamin ketersediaan obat bagi pasien sekaligus menghindari penumpukan stok kedaluwarsa. Dokumen ini mendeskripsikan fitur prediksi kebutuhan obat yang menerapkan Artificial Neural Network (ANN) jenis Multilayer Perceptron berarsitektur 9-12-8-1, ditulis murni dengan PHP tanpa library machine learning eksternal. Sumber data adalah pencatatan pemakaian obat yang diagregasi bulanan selama 12 bulan, direkayasa menjadi 9 fitur, dinormalisasi dengan z-score, dan dilatih dengan stochastic gradient descent disertai early stopping. Model dievaluasi dengan R², MAE, dan MAPE; prediksi dibuat 3 bulan ke depan secara autoregresif dengan fallback moving average bila data belum cukup, lalu diintegrasikan ke RKO dan permintaan obat.

Kata kunci: Prediksi Kebutuhan Obat; Artificial Neural Network; Backpropagation; Moving Average; R²; MAE; MAPE; RKO.

Abstract

Predicting drug demand at health facilities is essential to guarantee drug availability for patients while avoiding expired-stock accumulation. This document describes a drug-demand prediction feature implementing a 9-12-8-1 Multilayer Perceptron Artificial Neural Network (ANN), written purely in PHP without external machine learning libraries. Drug usage records aggregated monthly over 12 months are engineered into 9 features, normalized with z-score, and trained with stochastic gradient descent with early stopping. Models are evaluated with R², MAE, and MAPE; predictions cover 3 months ahead autoregressively with a moving-average fallback when data are insufficient, and are integrated into drug requirement planning (RKO) and drug requisitions.

Keywords: Drug Demand Prediction; Artificial Neural Network; Backpropagation; Moving Average; R²; MAE; MAPE; RKO.

1. Pendahuluan

Sistem informasi manajemen stok obat melayani Gudang Dinas, Puskesmas, dan Pustu. Tantangan utamanya adalah menentukan jumlah kebutuhan obat setiap periode secara akurat: kekurangan stok menghambat pelayanan pasien, sedangkan kelebihan stok berisiko kedaluwarsa dan memboroskan anggaran. Selama ini Rencana Kebutuhan Obat (RKO) disusun berbasis rekapitulasi manual sehingga kurang responsif terhadap pola konsumsi aktual.

Perkembangan Artificial Intelligence (AI) menghadirkan beragam teknik prediksi, salah satunya Artificial Neural Network (ANN) yang mengadopsi cara kerja jaringan syaraf. Algoritma Backpropagation Neural Network (BPNN) termasuk yang terbaik untuk prediksi, termasuk prediksi kebutuhan obat pada layanan kesehatan. Masalah yang diselesaikan adalah bagaimana merancang arsitektur ANN yang tepat beserta parameternya sehingga menghasilkan prediksi akurat, serta bagaimana hasil prediksi tersebut dapat langsung dipakai dalam perencanaan resmi faskes.

Dokumen ini bertujuan mendeskripsikan rancangan dan implementasi fitur prediksi kebutuhan obat pada sistem informasi manajemen stok obat: pengumpulan data, analisis data, perancangan arsitektur ANN, pelaksanaan prediksi, hasil dan pembahasan, serta kesimpulan.

2. Metodologi Penelitian

Tahapan prediksi kebutuhan obat terdiri dari pengumpulan data, analisis data, perancangan model arsitektur ANN, dan pelaksanaan prediksi, sebagaimana disajikan pada Gambar 1. Implementasi memakai PHP murni (Laravel 13, PHP 8.4, panel admin Filament) dengan basis data MySQL untuk pengembangan dan produksi; SQLite hanya dipakai untuk pengujian otomatis; penjadwalan training memakai Laravel Scheduler tiap Minggu jam 02:00.

Tabel 1. Lingkungan implementasi

Komponen	Teknologi
Bahasa implementasi AI	PHP (murni, tanpa library machine learning eksternal)
Framework aplikasi	Laravel 13, PHP 8.4, panel admin Filament
Basis data	MySQL untuk pengembangan dan produksi; SQLite hanya untuk testing
Model ANN	Kode sendiri: AnnTrainer (training), AnnModel (inferensi), AnnScaler (normalisasi)
Metode cadangan	MovingAverageService (rata-rata bergerak + confidence interval)
Penjadwalan	Laravel Scheduler: perintah ai:train-models tiap Minggu jam 02:00

Pengumpulan data -> Analisis data -> Perancangan arsitektur -> Pelaksanaan prediksi

Gambar 1. Tahapan prediksi kebutuhan obat

2.1. Pengumpulan Data

Data dikumpulkan dari pencatatan pemakaian obat (tabel pemakaian_obat dan detail_pemakaian_obat) per kombinasi fasilitas kesehatan dan obat. Setiap pemakaian otomatis mengurangi stok sehingga data ini mencerminkan konsumsi nyata. Untuk tiap kombinasi, sistem mengagregasi SUM(jumlah) per bulan selama 12 bulan terakhir, dihitung

mundur dari tanggal pemakaian terakhir pada faskes tersebut; bulan tanpa catatan diisi nol (zero-fill) agar deret kalender tetap utuh.

Data yang sama tercatat sebagai riwayat keluar dan menjadi dasar penyusunan LPLPO (Laporan Pemakaian dan Lembar Permintaan Obat), sehingga sumber training selaras dengan dokumen perencanaan resmi faskes sebagaimana dipakai pada penelitian acuan.

Tabel 2. Struktur penyimpanan data prediksi (MySQL)

Tabel	Peran dan constraint kunci
model_prediksi	Satu baris per kombinasi faskes+obat (unik); FK cascade ke fasilitas_kesehatan dan obat; index (status, tanggal_training); akurasi_r2 DECIMAL(5,4), mae DECIMAL(10,2), mape DECIMAL(5,2); status ENUM; bobot JSON di LONGTEXT + file
prediksi_kebutuhan	Unik (fasilitas_id, obat_id, periode_bulan, periode_tahun); FK model_id nullOnDelete; index kolom metode (ENUM); dibuat_oleh nullable (NULL = system-generated)
pemakaian_obat + detail	Sumber training; agregasi memakai DATE_FORMAT(tanggal_pemakaian, '%Y-%m') pada MySQL (strftime pada SQLite)
detail_rko	Konsumen hasil: prediksi_id nullable menautkan usulan RKO ke baris prediksi

Perubahan tipe ENUM (mis. penambahan metode ann_php) dijalankan via ALTER TABLE ... MODIFY ENUM khusus MySQL dan dilewati pada SQLite, karena kode AI ditulis dual-driver.

2.2. Analisis Data

Data yang dikumpulkan dianalisis dengan rekayasa fitur dan normalisasi. Dari deret 12 bulan dibentuk vektor 9 fitur untuk tiap titik waktu, sebagaimana Tabel 3.

Tabel 3. Fitur masukan model

No	Fitur	Keterangan
1	lag_1_bulan	Pemakaian satu bulan sebelumnya
2	lag_2_bulan	Pemakaian dua bulan sebelumnya
3	lag_3_bulan	Pemakaian tiga bulan sebelumnya
4	rata_rata_6_bulan	Rata-rata pemakaian 6 bulan terakhir
5	rata_rata_12_bulan	Rata-rata pemakaian 12 bulan terakhir
6	bulan	Nomor bulan 1-12 untuk menangkap pola musiman
7	trend_3_bulan	Kemiringan (slope) regresi linear 3 bulan terakhir

No	Fitur	Keterangan
8	stok_saat_ini	Stok berjalan (stok faskes; cadangan batch/gudang)
9	tipe_faskes	1 untuk puskesmas, 0 untuk pustu

Normalisasi dilakukan karena skala fitur sangat timpang (mis. lag ratusan unit vs tipe 0/1). Setiap fitur distandardisasi dengan z-score memakai mean dan std dari data training (AnnScaler); bila std nyaris nol ($< 1e-8$, fitur konstan), pembaginya diganti 1,0. Target (jumlah pemakaian) juga dinormalisasi lalu dikembalikan (denormalisasi / post-processing) saat prediksi agar keluar dalam satuan asli; parameter normalisasi ikut disimpan bersama bobot model.

2.3. Perancangan Model Arsitektur ANN

Arsitektur yang dirancang adalah Multilayer Perceptron (MLP) 9-12-8-1, sebagaimana Tabel 4, dengan total 233 parameter yang dipelajari.

Tabel 4. Rancangan arsitektur model ANN

Lapis	Neuron	Aktivasi	Parameter (bobot + bias)
Masukan	9	-	-
Tersembunyi 1	12	ReLU	$12 \times 9 + 12 = 120$
Tersembunyi 2	8	ReLU	$8 \times 12 + 8 = 104$
Keluaran	1	Linear	$1 \times 8 + 1 = 9$

Pembelajaran mengikuti tahapan Backpropagation: inisialisasi bobot awal, tahap aktivasi (forward pass menghitung output aktual lapis tersembunyi dan lapis keluaran), weight training (menghitung gradien error lapis keluaran lalu lapis tersembunyi dan mengubah bobot), dan tahap iterasi (pengulangan epoch hingga error minimal atau early stopping). Bobot diinisialisasi metode He ($w = \text{randn} \times \sqrt{2/\text{fan_in}}$, bias 0) yang adaptif per lapis; komposisi lapis tersembunyi 12-8 merupakan ketetapan konfigurasi sistem.

Tabel 5. Perbandingan dengan penelitian acuan (BPNN prediksi obat Puskesmas)

Aspek	Penelitian acuan	Sistem ini
Arsitektur	12-12-1 (12 input = 12 bulan)	9-12-8-1 (9 fitur rekayasa)
Normalisasi	Min-max ke rentang [0,1, 0,9]	Z-score per fitur + target
Aktivasi	Logsig hidden, purelin output	ReLU hidden, linear output
Split data	70% training / 30% testing	80% training / 20% testing
Iterasi	Epoch 1000 tetap	Epoch 800 + early stopping patience 20

Aspek	Penelitian acuan	Sistem ini
Pembelajaran	Learning rate 0,1 + momentum 0,9	SGD lr 0,01 + regularisasi L2
Perkakas	MATLAB	PHP murni (tanpa library ML)
Metrik	MAPE dan akurasi = 100% - MAPE	R2, MAE, MAPE (mentah)
Keluaran	Tabel prediksi tahunan	Prediksi 3 bulan + CI, terintegrasi RKO/permintaan

Tabel 6. Hiperparameter training

Aspek	Nilai / Ketentuan
Learning rate	0,01
Epoch maksimal	800, dengan early stopping patience 20 epoch pada split validasi internal
Regularisasi L2	1e-4
Split train/test	80/20; metrik hanya dihitung bila test set berisi minimal 2 sampel
Syarat data	Minimal 6 bulan berbeda dengan pemakaian > 0 dan minimal 2 vektor fitur
Jadwal	Cron tiap Minggu jam 02:00; maks 500 kombinasi per jalan; model aktif dilewati kecuali --force

2.4. Pelaksanaan Prediksi

Setelah data valid dan arsitektur siap, prediksi dilaksanakan. Model ANN memprediksi 3 bulan ke depan secara autoregresif (hasil bulan ke-i menjadi lag bulan berikutnya) disertai confidence interval 95% (+-1,96 SD historis); hasil dibulatkan dan tidak negatif. Bila data belum cukup, dipakai moving average. Perbandingan kedua metode pada Tabel 7.

Tabel 7. Metode prediksi

Aspek	ANN (ann_php)	Moving Average (moving_average)
Syarat	Data >= 6 bulan, model aktif	Data < 6 bulan (status data_belum_cukup)
Cara kerja	Prediksi 3 bulan autoregresif; hasil bulan ke-i menjadi lag bulan berikutnya	Rata-rata 3 bulan terakhir, diiterasi 3 bulan
Rentang	CI 95%: +-1,96 SD historis	CI 95%: +-1,96 SD jendela (bawah >= 0)

Aspek	ANN (ann_php)	Moving Average (moving_average)
Keluaran	Bulat, tidak negatif	Bulat, tidak negatif

Status model lain: kadaluarsa (digantikan training baru) dan gagal (pesan error tersimpan); keduanya tidak menghasilkan prediksi. Nilai metode lama (ai_gradient_boost, ai_random_forest) dipertahankan untuk data histori.

Tabel 8. Metrik evaluasi per model

Metrik	Keterangan
R2 (akurasi_r2)	Koefisien determinasi 0-1; makin dekat 1 makin baik
MAE (mae)	Mean Absolute Error; rata-rata selisih absolut vs aktual
MAPE (mape)	Mean Absolute Percentage Error dalam persen; periode aktual nol dilewati

Catatan konvensi: pada penelitian acuan, akurasi didefinisikan sebagai 100% dikurangi MAPE. Sistem ini menyimpan ketiga metrik dalam bentuk mentah (R2/MAE/MAPE) dan tidak menghitung skor akurasi turunan tersebut.

3. Hasil dan Pembahasan

3.1. Data

Tabel 9 menyajikan deret ilustrasi 12 bulan yang dipakai pada seluruh contoh dokumen ini (format mengikuti Tabel 1 penelitian acuan).

Tabel 9. Data pemakaian ilustrasi (unit)

Bulan	Pemakaian (unit)	Keterangan
Januari	95	Nilai minimum deret
Februari	100	
Maret	110	
April	105	
Mei	115	
Juni	120	
Juli	118	
Agustus	125	
September	130	

Bulan	Pemakaian (unit)	Keterangan
Oktober	120	
November	135	Nilai maksimum deret
Desember	128	

3.2. Normalisasi Data

Normalisasi memakai Rumus 1 dengan mean 116,75 dan std populasi 11,7836 dari deret Tabel 9; hasilnya pada Tabel 10 (format mengikuti Tabel 2 penelitian acuan).

Rumus 1.
$$x' = (x - \text{mean}) / \text{std}$$

Tabel 10. Data setelah normalisasi (z-score)

Bulan	Nilai z-score	Contoh hitung
Januari	-1,8458	(95 - 116,75) / 11,7836
Februari	-1,4215	
Maret	-0,5728	
April	-0,9971	
Mei	-0,1485	
Juni	0,2758	
Juli	0,1061	
Agustus	0,7001	
September	1,1244	
Oktober	0,2758	
November	1,5488	
Desember	0,9547	

Pembandingan metode: dengan rumus min-max penelitian acuan (rentang 0,1-0,9; min 95, maks 135), nilai 128 menjadi $0,8 \times (128-95)/(135-95) + 0,1 = 0,76$. Kedua metode sah dan hanya berbeda skala; sistem memakai z-score.

3.3. Penentuan Pola Data Latih dan Data Uji

Deret 12 bulan menghasilkan 9 vektor fitur valid karena vektor pertama baru dapat dibentuk pada bulan ke-4 (membutuhkan lag_1 sampai lag_3). Split 80/20 memakai $\text{floor}(9 \times 0,8) = 7$ vektor training dan 2 vektor testing; karena test set berisi minimal 2 sampel, ketiga metrik evaluasi terhitung.

Tabel 11. Pola data latih dan data uji (ilustrasi 12 bulan)

Tahap	Perhitungan	Jumlah
Deret bulanan	Jendela 12 bulan	12 titik
Vektor fitur valid	Bulan ke-4 s/d ke-12	9 vektor
Training (80%)	floor(9 x 0,8)	7 vektor
Testing (20%)	9 - 7	2 vektor

Catatan: nilai R2 hasil evaluasi dijepit pada rentang 0-1 sebelum disimpan. Bila test set berisi kurang dari 2 sampel, ketiga metrik dibiarkan NULL (belum terukur) dan model tetap dapat dipakai selama berstatus aktif.

3.4. Perancangan Model Arsitektur ANN

Rancangan mengikuti Tabel 4 dengan tahapan Backpropagation sebagaimana diuraikan pada 2.3. Struktur aliran model disajikan pada Gambar 2; legenda lambang pada Tabel 12; persamaan yang dipakai pada Rumus 2 sampai Rumus 4.

[9 fitur] -> [Tersembunyi 12, ReLU] -> [Tersembunyi 8, ReLU] -> [1 keluaran, Linear]

Gambar 2. Arsitektur model ANN 9-12-8-1

Tabel 12. Notasi pada algoritma backpropagation

Simbol	Arti
x	Vektor fitur masukan (9 fitur, lihat Tabel 3)
t	Nilai target (jumlah pemakaian aktual)
w	Bobot koneksi antar neuron
b	Bias / nilai ambang tiap neuron
z	Total masukan terbobot sebuah neuron
a	Keluaran aktivasi neuron tersembunyi
y	Keluaran prediksi neuron terakhir
lr	Learning rate / laju pembelajaran (0,01)
L2	Koefisien regularisasi bobot (1e-4)
grad (delta)	Gradien error hasil backpropagation
n	Jumlah sampel data
SD	Standar deviasi (simpangan baku)
T	Total prediksi pada horizon (rekomendasi)

Simbol	Arti
S	Stok saat ini (rekomendasi)

Rumus 2. $z = \text{jumlah}(w \times x) + b$; $a = \max(0, z)$; $y = \text{jumlah}(w \times a) + b$

Rumus 3. $\text{MSE} = (1/n) \times \text{jumlah}(y_{\text{pred}} - y_{\text{aktual}})^2$

Rumus 4. $w \leftarrow w - lr \times (\text{grad} + L2 \times w)$

Contoh satu neuron (ilustrasi): fitur lag_1 = 140 dengan mean 120 dan std 10 memberi z-score $(140-120)/10 = 2,0$. Neuron berbobot 0,5 dan bias -0,3 menghasilkan $z = 0,5 \times 2,0 - 0,3 = 0,7$ dan aktivasi ReLU $\max(0; 0,7) = 0,7$. Denormalisasi / post-processing: keluaran ternormalisasi 0,5 dengan yStd 20 dan yMean 100 menjadi $0,5 \times 20 + 100 = 110$ unit. Satu langkah SGD: $w = 0,5$ dengan gradien 0,4 menjadi $0,5 - 0,01 \times (0,4 + 1e-4 \times 0,5) = 0,4960$. Inisialisasi He: lapis pertama (fan_in = 9) memakai simpangan akar $(2/9) = 0,4714$, mis. undian 0,63 memberi bobot awal 0,297.

3.5. Prediksi Kuantitas Kebutuhan Obat

Contoh moving average: pemakaian 3 bulan terakhir 120, 135, 128 memberi rata-rata 128; SD sampel 7,51; margin $1,96 \times 7,51 = 15$; sehingga prediksi 128 (range 113-143).

Rumus 5. $\text{MA} = \text{jumlah}(y_{\text{ jendela}}) / \text{window}$; $\text{CI } 95\% = \text{MA} \pm 1,96 \times \text{SD}$

Tabel 13. Langkah moving average + CI (ilustrasi)

Langkah	Perhitungan	Hasil
1. Rata-rata	$(120 + 135 + 128) / 3 = 383 / 3$	127,67 dibulatkan 128
2. SD (sampel)	Jumlah kuadrat selisih = 112,67; dibagi 2; diakarkan	SD = 7,51
3. Margin 95%	$1,96 \times 7,51$	14,71 dibulatkan 15
4. Prediksi + CI	128; bawah = $\max(0, 128-15)$; atas = $128+15$	128 (range 113-143)

Contoh metrik: aktual [100, 120] vs prediksi [110, 115] memberi $\text{MAE} = (10+5)/2 = 7,5$; $\text{MAPE} = ((0,1)+(0,0417))/2 \times 100\% = 7,08\%$; $\text{R}^2 = 1 - 125/200 = 0,375$ (rata-rata aktual 110; SS_{tot} 200; SS_{res} 125).

Rumus 6. $\text{MAE} = \text{mean}|y - t|$; $\text{MAPE} = \text{mean}(|y - t| / t) \times 100\%$; $\text{R}^2 = 1 - \text{SS}_{\text{res}} / \text{SS}_{\text{tot}}$

Tabel 14. Contoh metrik evaluasi (ilustrasi)

Metrik	Perhitungan	Hasil
MAE	$(100-110 + 120-115) / 2 = (10 + 5) / 2$	7,5

Metrik	Perhitungan	Hasil
MAPE	$((10/100) + (5/120)) / 2 \times 100\%$	7,08%
R2	Rata-rata aktual = 110. SS_tot = 200. SS_res = 125	0,375

Mekanisme autoregresif (ilustrasi): prediksi bulan ke-1 memakai seluruh lag aktual menghasilkan 132; bulan ke-2 memakai lag_1 = 132 menghasilkan 129; bulan ke-3 memakai lag_1 = 129 dan lag_2 = 132 menghasilkan 131.

Tabel 15. Rollout autoregresif 3 bulan (ilustrasi)

Bulan	Sumber lag_1	Hasil ilustrasi
Bulan ke-1	Data aktual (128)	132
Bulan ke-2	Prediksi bulan ke-1 (132)	129
Bulan ke-3	Prediksi bulan ke-2 (129)	131

Hasil prediksi diubah menjadi rekomendasi pengadaan dengan Rumus 7. Contoh: total prediksi 3 bulan 300 unit dan stok 200 unit memberi $\text{ceil}(300 \times 1,20 - 200) = 160$ unit; coverage $(200/100) \times 30,44 = 60,9$ hari sehingga berstatus Perlu Pesan. Pembanding: stok 400 memberi rekom 0 (Aman); stok 30 memberi rekom 330 dengan coverage 9,13 hari < 21 hari (Kritis).

Rumus 7. $\text{rekom} = \max(0, \text{ceil}(T \times 1,20 - S))$

Tabel 16. Contoh rekomendasi pengadaan (ilustrasi)

Langkah	Perhitungan	Hasil
1. Kebutuhan + safety 20%	$300 \times 1,20$	360
2. Rekomendasi	$\text{ceil}(360 - 200), \text{ min } 0$	160 unit
3. Rata-rata bulanan	$300 / 3$	100 unit/bulan
4. Coverage	$(200 / 100) \times 30,44 \text{ hari}$	60,9 hari
5. Status	$\text{rekom} > 0 \text{ dan coverage} \geq 21 \text{ hari}$	Perlu Pesan

Uji kombinasi parameter berikut adalah ilustrasi grid-search mengikuti gaya Tabel 5 penelitian acuan, bukan hasil eksperimen yang dijalankan. Konfigurasi aktual sistem tetap: learning rate 0,01; epoch 800; L2 1e-4; patience 20.

Tabel 17. Ilustrasi pengujian parameter

Learning rate	Epoch	L2	Perilaku ilustratif
0,005	800	1e-4	Konvergen lambat, butuh epoch lebih banyak
0,01	800	1e-4	Stabil - konfigurasi aktif sistem
0,05	800	1e-4	Berisiko osilasi, loss tidak turun mulus
0,01	400	1e-4	Berhenti prematur, akurasi di bawah optimal
0,01	800	1e-3	Regularisasi terlalu kuat, model kurang peka

Pemanfaatan hasil: RKO terisi otomatis (keterangan Prediksi AI: jumlah + range, atau tombol Generate dari Prediksi untuk semua obat aktif dengan penanda kolom AI; rumus Kemenkes tetap berlaku) dan petugas faskes dapat membuat permintaan obat langsung dari halaman Prediksi AI. Hak akses pada Tabel 18; pengoperasian via php artisan ai:train-models (opsi --fasilitas-id, --obat-id, --force), menu Prediksi AI, dan agregat Dashboard AI. Pengujian otomatis: MovingAverageServiceTest (7 test) dan AiTrainModelsCommandTest (2 test).

Tabel 18. Hak akses fitur prediksi

Permission	Super Admin	Gudang	Dinas	Puskes. / Pustu
view_model_prediksi	Ya	Ya	Ya	Ya / Tidak
view_prediksi_kebutuhan	Ya	Ya	Ya	Ya / Ya
create/update/delete	Ya	Tidak	Tidak	Tidak

4. Kesimpulan

Fitur prediksi kebutuhan obat menerapkan Jaringan Saraf Tiruan MLP 9-12-8-1 yang ditulis murni dengan PHP: data pemakaian diagregasi bulanan, direkayasa menjadi 9 fitur, dinormalisasi z-score, dilatih dengan SGD + early stopping, dievaluasi dengan R2/MAE/MAPE, lalu dipakai memprediksi 3 bulan ke depan secara autoregresif dengan fallback moving average bila data belum cukup.

Dibanding penelitian acuan (BPNN 12-12-1, min-max, MATLAB, keluaran tabel tahunan), sistem ini memakai fitur rekayasa yang lebih kaya, fungsi aktivasi ReLU, split 80/20, penyimpanan model ganda (JSON + file), serta integrasi langsung ke RKO dan permintaan obat sehingga hasil prediksi dapat dieksekusi menjadi perencanaan.

Batasan yang perlu dicatat: komposisi lapis tersembunyi 12-8 adalah ketetapan konfigurasi (bukan hasil trial-and-error); model membutuhkan minimal 6 bulan berisi agar ANN dipakai;

sistem menyimpan metrik mentah tanpa skor akurasi turunan 100%-MAPE.

Saran pengembangan: uji variasi hiperparameter secara sistematis, penjadwalan retraining adaptif berbasis drift akurasi, serta penambahan fitur kalender dan musim penyakit.

Daftar Rujukan

[1] F. Khairati dan H. Putra, Prediksi Kuantitas Penggunaan Obat pada Layanan Kesehatan Menggunakan Algoritma Backpropagation Neural Network, Jurnal Sistim Informasi dan Teknologi, vol. 4, no. 3, hal. 128-135, 2022, doi: 10.37034/jsisfotek.v4i3.158.