

Dokumentasi Fitur Prediksi Kebutuhan Obat dengan Kecerdasan Buatan

1. Bahasa dan Teknologi yang Dipakai

Komponen	Teknologi
Bahasa implementasi AI	PHP (murni, tanpa library machine learning eksternal)
Framework aplikasi	Laravel 13, PHP 8.4, panel admin Filament
Basis data	MySQL untuk pengembangan dan produksi; SQLite hanya untuk testing (rinci di Bab 10)
Model ANN	Kode sendiri: AnnTrainer (training), AnnModel (inferensi), AnnScaler (normalisasi)
Metode cadangan	MovingAverageService (rata-rata bergerak + confidence interval)
Penjadwalan	Laravel Scheduler: perintah ai:train-models tiap Minggu jam 02:00

2. Sumber Data

Sumber data utama adalah pencatatan pemakaian obat (tabel pemakaian_obat dan detail_pemakaian_obat). Setiap pemakaian otomatis mengurangi stok sehingga data ini mencerminkan konsumsi nyata di fasilitas kesehatan.

Untuk tiap kombinasi faskes dan obat, sistem mengagregasi SUM(jumlah) per bulan selama 12 bulan terakhir, dihitung mundur dari tanggal pemakaian terakhir pada faskes tersebut. Bulan tanpa catatan diisi nol (zero-fill) agar deret kalender tetap utuh untuk perhitungan fitur lag.

Data yang sama juga tercatat sebagai riwayat keluar dan menjadi dasar penyusunan LPLPO (Laporan Pemakaian dan Lembar Permintaan Obat), sehingga sumber training selaras dengan dokumen perencanaan resmi faskes sebagaimana dipakai pada penelitian acuan.

3. Rekayasa Fitur (Feature Engineering)

Dari deret 12 bulan dibentuk vektor 9 fitur untuk tiap titik waktu:

No	Fitur	Keterangan
1	lag_1_bulan	Pemakaian satu bulan sebelumnya
2	lag_2_bulan	Pemakaian dua bulan sebelumnya
3	lag_3_bulan	Pemakaian tiga bulan sebelumnya

No	Fitur	Keterangan
4	rata_rata_6_bulan	Rata-rata pemakaian 6 bulan terakhir
5	rata_rata_12_bulan	Rata-rata pemakaian 12 bulan terakhir
6	bulan	Nomor bulan 1-12 untuk menangkap pola musiman
7	trend_3_bulan	Kemiringan (slope) regresi linear 3 bulan terakhir
8	stok_saat_ini	Stok berjalan (stok faskes; cadangan batch/gudang)
9	tipe_faskes	1 untuk puskesmas, 0 untuk pustu

4. Normalisasi Data

Skala fitur sangat timpang (mis. lag ratusan unit vs tipe 0/1), sehingga sebelum training setiap fitur distandardisasi dengan z-score: $(x - \text{mean}) / \text{std}$, memakai mean dan std yang dihitung dari data training (AnnScaler). Jika std nyaris nol ($< 1e-8$, fitur konstan), pembagiannya diganti 1,0 agar tidak terjadi pembagian nol. Target (jumlah pemakaian) juga dinormalisasi dengan mean/std-nya sendiri, lalu dikembalikan (denormalisasi) saat prediksi agar keluar dalam satuan asli. Parameter normalisasi (means, stds, yMean, yStd) ikut disimpan bersama bobot model supaya inferensi memakai skala yang identik dengan training.

5. Arsitektur Jaringan (Layer)

Model adalah Multilayer Perceptron (MLP) 9-12-8-1:

Lapis	Neuron	Aktivasi	Parameter (bobot + bias)
Masukan	9	-	-
Tersembunyi 1	12	ReLU	$12 \times 9 + 12 = 120$
Tersembunyi 2	8	ReLU	$8 \times 12 + 8 = 104$
Keluaran	1	Linear	$1 \times 8 + 1 = 9$

Total 233 parameter yang dipelajari. Fungsi loss adalah mean squared error (MSE); optimasi memakai stochastic gradient descent (update per sampel, data diacak tiap epoch); bobot diinisialisasi metode He dan diberi regularisasi L2.

Pembelajaran mengikuti tahapan Backpropagation (BPNN): inisialisasi bobot awal, tahap aktivasi (forward pass menghitung output aktual lapis tersembunyi dan lapis keluaran), weight training (menghitung gradien error lapis keluaran lalu lapis tersembunyi dan mengubah bobot), dan tahap iterasi (pengulangan epoch hingga error minimal atau early stopping).

Komposisi lapis tersembunyi 12-8 merupakan ketetapan konfigurasi sistem, bukan hasil

trial-and-error.

5.1. Perbandingan dengan Penelitian Acuan (BPNN Prediksi Obat Puskesmas)

Aspek	Penelitian acuan	Sistem ini
Arsitektur	12-12-1 (12 input = 12 bulan)	9-12-8-1 (9 fitur rekayasa)
Normalisasi	Min-max ke rentang [0,1, 0,9]	Z-score per fitur + target
Aktivasi	Logsig hidden, purelin output	ReLU hidden, linear output
Split data	70% training / 30% testing	80% training / 20% testing
Iterasi	Epoch 1000 tetap	Epoch 800 + early stopping patience 20
Pembelajaran	Learning rate 0,1 + momentum 0,9	SGD lr 0,01 + regularisasi L2
Perkakas	MATLAB	PHP murni (tanpa library ML)
Metrik	MAPE dan akurasi = 100% - MAPE	R2, MAE, MAPE (mentah)
Keluaran	Tabel prediksi tahunan	Prediksi 3 bulan + CI, terintegrasi RKO/permintaan

6. Proses Training dan Evaluasi

Aspek	Nilai / Ketentuan
Learning rate	0,01
Epoch maksimal	800, dengan early stopping patience 20 epoch pada split validasi internal
Regularisasi L2	1e-4
Split train/test	80/20; metrik hanya dihitung bila test set berisi minimal 2 sampel
Syarat data	Minimal 6 bulan berbeda dengan pemakaian > 0 dan minimal 2 vektor fitur
Jadwal	Cron tiap Minggu jam 02:00; maks 500 kombinasi per jalan; model aktif dilewati kecuali --force

Metrik evaluasi yang disimpan per model:

Metrik	Keterangan
R2 (akurasi_r2)	Koefisien determinasi 0-1; makin dekat 1 makin baik

Metrik	Keterangan
MAE (mae)	Mean Absolute Error; rata-rata selisih absolut vs aktual
MAPE (mape)	Mean Absolute Percentage Error dalam persen; periode aktual nol dilewati

Catatan konvensi: pada penelitian acuan, akurasi didefinisikan sebagai 100% dikurangi MAPE. Sistem ini menyimpan ketiga metrik dalam bentuk mentah (R²/MAE/MAPE) dan tidak menghitung skor akurasi turunan tersebut.

6.1. Inisialisasi Bobot Awal

Bobot diinisialisasi metode He: $w = \text{randn} \times \text{akar}(2/\text{fan_in})$ dengan bias 0, sehingga skala awal menyesuaikan tiap lapis. Contoh lapis pertama ($\text{fan_in} = 9$): simpangan inisialisasi = $\text{akar}(2/9) = 0,4714$; bila undian randn menghasilkan 0,63 maka satu bobot awal = $0,63 \times 0,4714 = 0,297$. Berbeda dengan penelitian acuan yang memakai rentang tetap 0,05-0,08, inisialisasi He bersifat adaptif terhadap lebar lapis.

6.2. Contoh Jumlah Sampel dari Split

Deret 12 bulan hanya menghasilkan 9 vektor fitur valid, karena vektor pertama baru dapat dibentuk pada bulan ke-4 (membutuhkan lag₁ sampai lag₃). Split 80/20 memakai $\text{floor}(9 \times 0,8) = 7$ vektor training dan 2 vektor testing; karena test set berisi minimal 2 sampel, ketiga metrik evaluasi terhitung.

Tahap	Perhitungan	Jumlah
Deret bulanan	Jendela 12 bulan	12 titik
Vektor fitur valid	Bulan ke-4 s/d ke-12	9 vektor
Training (80%)	$\text{floor}(9 \times 0,8)$	7 vektor
Testing (20%)	9 - 7	2 vektor

7. Inferensi dan Metode Cadangan

Aspek	ANN (ann_php)	Moving Average (moving_average)
Syarat	Data ≥ 6 bulan, model aktif	Data < 6 bulan (status data_belum_cukup)
Cara kerja	Prediksi 3 bulan autoregresif; hasil bulan ke-i menjadi lag bulan berikutnya	Rata-rata 3 bulan terakhir, diiterasi 3 bulan

Aspek	ANN (ann_php)	Moving Average (moving_average)
Rentang	CI 95%: +-1,96 SD historis	CI 95%: +-1,96 SD jendela (bawah ≥ 0)
Keluaran	Bulat, tidak negatif	Bulat, tidak negatif

Status model lain: kadaluarsa (digantikan training baru), gagal (pesan error tersimpan), keduanya tidak menghasilkan prediksi. Nilai metode lama (ai_gradient_boost, ai_random_forest) dipertahankan untuk data histori.

8. Diagram Alur End-to-End

No	Fase	Masukan	Keluaran
1	Pengumpulan data	pemakaian_obat + detail (per faskes+obat)	Deret 12 bulan, zero-fill
2	Rekayasa fitur	Deret bulanan + stok + tipe faskes	Vektor 9 fitur per titik waktu
3	Normalisasi	Vektor fitur + target	Data z-score + parameter scaler
4	Training + evaluasi	Data ternormalisasi (split 80/20)	Bobot ANN + R2/MAE/MAPE
5	Penyimpanan	Bobot + scaler + metrik	model_prediksi + file JSON
6	Inferensi	Model aktif + fitur bulan berjalan	prediksi_kebutuhan 3 bulan + CI
7	Rekomendasi	Prediksi horizon + stok	Rekom order + status + KPI
8	Integrasi	Rekomendasi/prediksi	RKO terisi + permintaan obat

9. Diagram Penyimpanan (Tabel dan Relasi)

Tabel	Kolom kunci dan relasi
model_prediksi	PK id; FK fasilitas_id -> fasilitas_kesehatan; FK obat_id -> obat; unik (fasilitas_id, obat_id); bobot di model_data (JSON) + model_path (file); metrik akurasi_r2, mae, mape; status aktif/kadaluarsa/gagal/data_belum_cukup
prediksi_kebutuhan	PK id; FK fasilitas_id; FK obat_id; FK model_id -> model_prediksi (nullable); unik (fasilitas_id, obat_id, periode_bulan, periode_tahun); jumlah_prediksi + confidence_lower/upper; metode ann_php/moving_average/manual

Tabel	Kolom kunci dan relasi
detail_rko	FK prediksi_id -> prediksi_kebutuhan (nullable): jejak usulan RKO yang berasal dari AI

10. Basis Data MySQL

MySQL adalah sistem manajemen basis data utama untuk pengembangan dan produksi (DB_CONNECTION=mysql, port 3306). SQLite hanya dipakai untuk pengujian otomatis (in-memory) sehingga kode AI ditulis dual-driver: agregasi bulanan memakai DATE_FORMAT di MySQL dan strftime di SQLite, sedangkan perubahan tipe ENUM (mis. penambahan metode ann_php) dijalankan via ALTER TABLE ... MODIFY ENUM khusus MySQL dan dilewati pada SQLite.

Tabel inti fitur ini:

Tabel	Peran dan constraint kunci
model_prediksi	Satu baris per kombinasi faskes+obat (unik); FK cascade ke fasilitas_kesehatan dan obat; index (status, tanggal_training); kolom presisi: akurasi_r2 DECIMAL(5,4), mae DECIMAL(10,2), mape DECIMAL(5,2); status ENUM; bobot JSON di LONGTEXT + file
prediksi_kebutuhan	Unik (fasilitas_id, obat_id, periode_bulan, periode_tahun) mencegah duplikat; FK model_id nullOnDelete; index kolom metode (ENUM); dibuat_oleh nullable (NULL = system-generated)
pemakaian_obat + detail	Sumber training; agregasi SUM(jumlah) per bulan per faskes+obat memakai DATE_FORMAT(tanggal_pemakaian, '%Y-%m')
detail_rko	Konsumen hasil: prediksi_id nullable menautkan usulan RKO ke baris prediksi

11. Rekomendasi Pengadaan

Rumus: rekom = pembulatan_ke_atas(total_prediksi_horizon x 1,20 - stok_saat_ini), batas bawah nol. Faktor 1,20 adalah safety stock 20%.

Status per obat: Aman (rekom nol), Kritis (cakupan stok < 21 hari), Perlu Pesan; diurutkan berdasar defisit relatif terbesar. Tersedia KPI (obat diprediksi, obat defisit, estimasi anggaran), 5 lonjakan tertinggi, dan rincian per obat (prediksi + CI, tren realisasi 12 bulan, info model, stok gudang, faktor penjelasan).

12. Integrasi RKO, Permintaan, dan Hak Akses

Auto-fill RKO: saat pengguna memilih obat pada form RKO, kolom keterangan terisi otomatis, contoh: "Prediksi AI: 500 (range: 450 - 550)", dan tetap dapat diubah manual.

Generate dari Prediksi (bulk): satu tombol mengisi seluruh obat aktif sekaligus memakai nilai prediksi bulan terbaru, dengan penanda kolom AI; rumus Kemenkes tetap berlaku. Buat permintaan: petugas faskes dapat membuat permintaan langsung dari halaman Prediksi AI (bulk/per obat) tercatat sumber periodenya.

Permission	Super Admin	Gudang	Dinas	Puskes. / Pustu
view_model_prediksi	Ya	Ya	Ya	Ya / Tidak
view_prediksi_kebutuhan	Ya	Ya	Ya	Ya / Ya
create/update/delete	Ya	Tidak	Tidak	Tidak

13. Cara Penggunaan dan Pengujian

Training: php artisan ai:train-models (opsi --fasilitas-id, --obat-id, --force) atau aksi training di halaman Prediksi AI. Melihat hasil: menu Prediksi AI (filter faskes/kategori/bulan/tahun/horizon), rincian per obat, dan agregat di Dashboard AI. Perencanaan: RKO via auto-fill atau Generate dari Prediksi; permintaan via halaman Prediksi AI.

Pengujian otomatis: MovingAverageServiceTest (7 test) dan AiTrainModelsCommandTest (2 test).

14. Contoh Perhitungan

Seluruh angka di bawah adalah data ilustrasi untuk menunjukkan cara kerja rumus, bukan data produksi.

14.1. Moving Average + Confidence Interval 95%

Diketahui pemakaian 3 bulan terakhir: 120, 135, 128.

Langkah	Perhitungan	Hasil
1. Rata-rata	$(120 + 135 + 128) / 3 = 383 / 3$	127,67 dibulatkan 128

Langka h	Perhitungan	Hasil
2. Standar deviasi (sampel)	Selisih: -7,67; 7,33; 0,33. Kuadrat dijumlah = 112,67; dibagi (3-1) = 56,33; diakarkan	SD = 7,51
3. Margin 95%	$1,96 \times 7,51$	14,71 dibulatkan 15
4. Prediksi + CI	128; bawah = $\max(0, 128-15)$; atas = $128+15$	128 (range 113-143)

14.2. Normalisasi dan Satu Neuron ANN

Misalkan fitur lag_1_bulan bernilai 140 sedangkan mean training 120 dan std 10. Skor $z = (140 - 120) / 10 = 2,0$. Nilai 2,0 inilah yang masuk ke jaringan, bukan 140.

Ambil satu neuron tersembunyi (ilustrasi) dengan bobot 0,5 dan bias -0,3 untuk input tunggal tersebut: $z = 0,5 \times 2,0 + (-0,3) = 0,7$. Aktivasi ReLU: $\max(0; 0,7) = 0,7$. Pada model sebenarnya operasi ini terjadi serentak pada 233 parameter berlapis 9-12-8-1.

Denormalisasi / post-processing (ilustrasi): misalkan keluaran ternormalisasi 0,5 dengan $y_{Std} = 20$ dan $y_{Mean} = 100$, maka prediksi = $0,5 \times 20 + 100 = 110$ unit obat. Tahap ini mengembalikan nilai ke satuan data awal.

Belajar bobot / SGD (ilustrasi satu langkah): bobot $w = 0,5$, gradien error 0,4, $L2 = 1e-4$, learning rate 0,01. $w_{baru} = 0,5 - 0,01 \times (0,4 + 1e-4 \times 0,5) = 0,5 - 0,0040005 = 0,4960$ (dibulatkan 4 desimal). Langkah ini diulang untuk seluruh 233 parameter pada tiap sampel, tiap epoch.

Tahap	Rumus contoh	Hasil contoh
Normalisasi fitur	$(140 - 120) / 10$	$z = 2,0$
Neuron (ReLU)	$\max(0; 0,5 \times 2,0 - 0,3)$	0,7
Denormalisasi output	$0,5 \times 20 + 100$	110 unit
Update bobot (SGD)	$0,5 - 0,01 \times (0,4 + 1e-4 \times 0,5)$	$w = 0,4960$

Catatan: bila std sebuah fitur nyaris nol ($< 1e-8$), pembagiannya diganti 1,0 agar tidak terjadi pembagian nol.

14.3. Metrik Evaluasi R2, MAE, MAPE

Diketahui aktual [100, 120] dan prediksi model [110, 115].

Metrik	Perhitungan	Hasil
MAE	$(100-110 + 120-115) / 2 = (10 + 5) / 2$	7,5
MAPE	$((10/100) + (5/120)) / 2 \times 100\% = (0,1 + 0,0417) / 2 \times 100\%$	7,08%
R2	Rata-rata aktual = 110. $SS_{tot} = 100 + 100 = 200$. $SS_{res} = 100 + 25 = 125$. $R2 = 1 - 125/200$	0,375

Catatan: nilai R2 hasil evaluasi dijepit pada rentang 0-1 sebelum disimpan. Bila test set berisi kurang dari 2 sampel, ketiga metrik dibiarkan NULL (belum terukur) dan model tetap dapat dipakai selama berstatus aktif.

14.4. Rekomendasi Pengadaan dan Status

Diketahui total prediksi 3 bulan = 300 unit dan stok saat ini = 200 unit.

Langkah	Perhitungan	Hasil
1. Kebutuhan + safety 20%	$300 \times 1,20$	360
2. Rekomendasi	$\text{ceil}(360 - 200), \text{min } 0$	160 unit
3. Rata-rata bulanan	$300 / 3$	100 unit/bulan
4. Coverage	$(200 / 100) \times 30,44 \text{ hari}$	60,9 hari
5. Status	rekom > 0 dan coverage 60,9 hari (≥ 21 hari)	Perlu Pesan

Dua kasus pembandingan (prediksi sama = 300 unit): stok 400 unit menghasilkan $\text{ceil}(360 - 400)$ yang negatif sehingga dibatasi 0 (tidak perlu pesan) dengan status Aman; stok 30 unit menghasilkan rekom $\text{ceil}(360 - 30) = 330$ unit dengan coverage $(30/100) \times 30,44 = 9,13$ hari (< 21 hari) sehingga berstatus Kritis.

Kasus	Perhitungan	Hasil
Aman (stok 400)	$\text{ceil}(300 \times 1,20 - 400)$ dibatasi ≥ 0	rekom 0
Kritis (stok 30)	rekom = 330; coverage = 9,13 hari < 21 hari	rekom 330

14.5. Pembentukan Vektor 9 Fitur

Diketahui deret pemakaian 12 bulan (ilustrasi): 95, 100, 110, 105, 115, 120, 118, 125, 130, 120, 135, 128. Target prediksi adalah bulan ke-13 (mis. Januari sehingga fitur bulan = 1), stok

saat ini 200, tipe puskesmas (1).

Fitur	Perhitungan	Hasil
lag_1, lag_2, lag_3	3 nilai terakhir deret	128, 135, 120
rata_rata_6_bulan	$(118+125+130+120+135+128) / 6 = 756 / 6$	126,0
rata_rata_12_bulan	jumlah 12 bulan = 1401; $1401 / 12$	116,75
trend_3_bulan	Slope 3 nilai terakhir [120, 135, 128]: pembilang 8,0; penyebut 2,0	4,0 (naik)
bulan / stok / tipe	Diketahui langsung	1 / 200 / 1

Vektor final: [128, 135, 120, 126, 116.75, 1, 4.0, 200, 1]. Vektor inilah (setelah dinormalisasi) yang menjadi masukan 9 neuron lapis pertama.

14.6. Rollout Autoregresif 3 Bulan dan Aturan Data Minimum

Mekanisme autoregresif (ilustrasi): prediksi bulan-1 memakai seluruh lag aktual menghasilkan 132; prediksi bulan-2 memakai lag_1 = 132 (hasil bulan-1) menghasilkan 129; prediksi bulan-3 memakai lag_1 = 129 dan lag_2 = 132 menghasilkan 131. Tiap nilai dibulatkan dan disertai CI $\pm 1,96$ SD historis.

Bulan	Sumber lag_1	Hasil ilustrasi
Bulan ke-1	Data aktual (128)	132
Bulan ke-2	Prediksi bulan ke-1 (132)	129
Bulan ke-3	Prediksi bulan ke-2 (129)	131

Aturan data minimum (ilustrasi): bila dalam jendela 12 bulan hanya 4 bulan yang pemakaiannya > 0 , maka $4 < 6$ sehingga model berstatus data_belum_cukup dan prediksi memakai moving average (metode moving_average), bukan ANN.

14.7. Tabel Data dan Tabel Data Setelah Normalisasi

Dua tabel berikut menyajikan deret ilustrasi yang dipakai pada contoh 14.5, dengan format mengikuti Tabel 1 dan Tabel 2 penelitian acuan. Tabel pertama adalah data mentah; tabel kedua adalah hasilnya setelah normalisasi z-score sistem (mean 116,75 dan std populasi 11,7836 dari deret yang sama).

Bulan	Pemakaian (unit)	Keterangan
Januari	95	Nilai minimum deret
Februari	100	

Bulan	Pemakaian (unit)	Keterangan
Maret	110	
April	105	
Mei	115	
Juni	120	
Juli	118	
Agustus	125	
September	130	
Oktober	120	
November	135	Nilai maksimum deret
Desember	128	

Bulan	Nilai z-score	Contoh hitung
Januari	-1,8458	$(95 - 116,75) / 11,7836$
Februari	-1,4215	
Maret	-0,5728	
April	-0,9971	
Mei	-0,1485	
Juni	0,2758	
Juli	0,1061	
Agustus	0,7001	
September	1,1244	
Oktober	0,2758	
November	1,5488	
Desember	0,9547	

Penegas metode: tabel di atas memakai z-score sistem. Dengan rumus min-max penelitian acuan (rentang 0,1-0,9; min 95, maks 135), nilai 128 menjadi $0,8 \times (128-95)/(135-95) + 0,1 = 0,76$. Kedua metode sah dan hanya berbeda skala; sistem memakai z-score sebagaimana dijelaskan pada Bab 4 dan tabel perbandingan 5.1.

15. Rumus dan Notasi

Bab ini menghimpun seluruh persamaan yang dipakai fitur ini beserta legenda lambangnya, mengikuti kelaziman penulisan penelitian acuan.

No	Rumus	Keterangan
1	$x' = (x - \text{mean}) / \text{std}$	Normalisasi z-score fitur dan target
2	$z = \text{jumlah}(w \times x) + b; a = \max(0, z)$	Neuron tersembunyi (aktivasi ReLU)
3	$y = \text{jumlah}(w \times a) + b$	Neuron keluaran (aktivasi linear)
4	$\text{MSE} = (1/n) \times \text{jumlah}(y_{\text{pred}} - y_{\text{aktual}})^2$	Fungsi loss training
5	$w \leftarrow w - \text{lr} \times (\text{grad} + \text{L2} \times w)$	Update bobot SGD + regularisasi L2
6	$\text{MA} = \text{jumlah}(y_{\text{jendela}}) / \text{window}; \text{CI} = \text{MA} \pm 1,96 \times \text{SD}$	Moving average + CI 95%
7	$\text{rekom} = \max(0, \text{ceil}(T \times 1,20 - S))$	Rekomendasi + safety stock 20%
8	$R^2 = 1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}; \text{MAE}; \text{MAPE}$	Metrik evaluasi (lihat Bab 6)

Simbol	Arti
x	Vektor fitur masukan (9 fitur, lihat Bab 3)
t	Nilai target (jumlah pemakaian aktual)
w	Bobot koneksi antar neuron
b	Bias / nilai ambang tiap neuron
z	Total masukan terbobot sebuah neuron
a	Keluaran aktivasi neuron tersembunyi
y	Keluaran prediksi neuron terakhir
lr	Learning rate / laju pembelajaran (0,01)
L2	Koefisien regularisasi bobot ($1e-4$)
grad (delta)	Gradien error hasil backpropagation
n	Jumlah sampel data
SD	Standar deviasi (simpangan baku)
T	Total prediksi pada horizon (lihat Bab 11)
S	Stok saat ini (lihat Bab 11)

16. Kesimpulan

Fitur prediksi kebutuhan obat menerapkan Jaringan Saraf Tiruan MLP 9-12-8-1 yang ditulis murni dengan PHP: data pemakaian diagregasi bulanan, direkayasa menjadi 9 fitur, dinormalisasi z-score, dilatih dengan SGD + early stopping, dievaluasi dengan R2/MAE/MAPE, lalu dipakai memprediksi 3 bulan ke depan secara autoregresif dengan fallback moving average bila data belum cukup.

Dibanding penelitian acuan (BPNN 12-12-1, min-max, MATLAB, keluaran tabel tahunan), sistem ini memakai fitur rekayasa yang lebih kaya, fungsi aktivasi ReLU, split 80/20, penyimpanan model ganda (JSON + file), serta integrasi langsung ke RKO dan permintaan obat sehingga hasil prediksi dapat dieksekusi menjadi perencanaan.

Batasan yang perlu dicatat: komposisi lapis tersembunyi 12-8 adalah ketetapan konfigurasi (bukan hasil trial-and-error); model membutuhkan minimal 6 bulan berisi agar ANN dipakai; sistem menyimpan metrik mentah tanpa skor akurasi turunan 100%-MAPE.

Saran pengembangan: uji variasi hiperparameter secara sistematis (lihat Bab 17), penjadwalan retraining adaptif berbasis drift akurasi, serta penambahan fitur kalender (mis. hari libur) dan musim penyakit.

17. Pengujian Parameter

Tabel berikut adalah ilustrasi grid-search variasi hiperparameter mengikuti gaya Tabel 5 penelitian acuan. Nilai-nilainya bersifat ilustratif untuk menunjukkan cara membaca hasil uji, bukan hasil eksperimen yang dijalankan. Konfigurasi aktual sistem tetap: learning rate 0,01; epoch 800; L2 1e-4; patience 20 (ditandai aktif).

Learning rate	Epoch	L2	Perilaku ilustratif
0,005	800	1e-4	Konvergen lambat, butuh epoch lebih banyak
0,01	800	1e-4	Stabil - konfigurasi aktif sistem
0,05	800	1e-4	Berisiko osilasi, loss tidak turun mulus
0,01	400	1e-4	Berhenti prematur, akurasi di bawah optimal
0,01	800	1e-3	Regularisasi terlalu kuat, model kurang peka